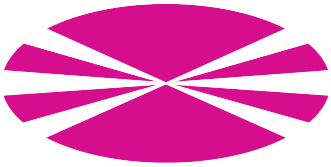

Resumen

Esta práctica aborda la clasificación automática de imágenes capturadas por cámaras CCTV en entornos portuarios, en el marco de una plataforma **Smartports**. Se implementan y comparan cuatro configuraciones de modelos de red neuronal convolucional para dos tareas de clasificación binaria: **Ship/No-Ship** y **Docked/Undocked**. Los mejores resultados en Ship/No-Ship se obtienen con modelos preentrenados (ResNet18), alcanzando un **100 % de accuracy** en validación. Para la tarea Docked/Undocked, más desafiante, el mejor modelo logra un **89.2 % de accuracy**.

Índice

1. Introducción y Contexto **2**

2. Dataset **2**
2.1. Descripción . . . 2
2.2. Etiquetado y distribución . . . 2
2.3. Partición train/validación . . . 2

3. Metodología **3**
3.1. Tarea 1 — Dataset Personalizado . . . 3
3.2. Transformaciones y Data Augmentation . . . 3
3.3. Arquitecturas de Red . . . 3
3.3.1. Modelo desde cero — SimpleCNN . . . 3
3.3.2. Modelo preentrenado — ResNet18 Fine-tuning . . . 3
3.4. Configuración de Entrenamiento . . . 4

4. Tarea 2 — Clasificación Ship/No-Ship **4**
4.1. Curvas de Entrenamiento . . . 4
4.2. Resultados Cuantitativos . . . 5
4.3. Matrices de Confusión . . . 5
4.4. Análisis . . . 5

5. Tarea 4 — Clasificación Docked/Undocked (Opcional) **5**
5.1. Curvas de Entrenamiento . . . 6
5.2. Resultados Cuantitativos . . . 6
5.3. Matrices de Confusión . . . 6
5.4. Análisis . . . 7

6. Comparativa Global y Conclusiones **7**
6.1. Comparativa entre tareas . . . 7
6.2. Conclusiones . . . 7

Introducción y Contexto

La gestión inteligente de infraestructuras portuarias requiere sistemas capaces de monitorizar en tiempo real el flujo de embarcaciones. El módulo de videovigilancia de la plataforma **Smartports** analiza el flujo de vídeo de cámaras CCTV para detectar automáticamente eventos de atraque y desatraque, registrando el instante temporal y enviando notificaciones con la información asociada a cada operación.

Se identifican dos tareas de clasificación de imágenes de especial relevancia:

- **Ship/No-Ship**: determinar si hay algún barco presente en la escena.
- **Docked/Undocked**: determinar si el barco presente está atracado o no.

Ambas tareas presentan retos específicos del dominio: variabilidad en las condiciones de iluminación (día/noche, contraluz), diferentes puntos de vista de cámara, escala variable de las embarcaciones y condiciones meteorológicas adversas.

Dataset

Descripción

El dataset está compuesto por **294 imágenes** capturadas por diferentes cámaras instaladas en entornos portuarios reales, con resolución de 640×464 píxeles. Las imágenes presentan gran variabilidad en condiciones de iluminación, hora del día y punto de vista de la cámara.

Etiquetado y distribución

Cuadro 1: Distribución de clases en el dataset

Tarea	Total	Clase 0	Clase 1	Balance
Ship/No-Ship	294	110 (No Ship)	184 (Ship)	37 / 63 %
Docked/Undocked	184	92 (Undocked)	92 (Docked)	50 / 50 %

Partición train/validación

Se realiza una división **80 %/20 % estratificada**:

Cuadro 2: Partición del dataset

Tarea	Train	Clase 0	Clase 1	Val
Ship/No-Ship	235	88	147	59
Docked/Undocked	147	73	74	37

Metodología

Tarea 1 — Dataset Personalizado

Se implementa la clase `PortDataset`, heredando de `torch.utils.data.Dataset`, que gestiona la carga de imágenes desde disco y la asignación de etiquetas desde los ficheros CSV. La clase acepta transformaciones opcionales, permitiendo aplicar data augmentation de forma transparente durante el entrenamiento.

Transformaciones y Data Augmentation

Se definen dos pipelines de transformación adaptados al dominio portuario:

Sin Data Augmentation (Base)

Resize a 224×224 píxeles, conversión a tensor y normalización con estadísticos de ImageNet: $\mu = [0{,}485, 0{,}456, 0{,}406]$, $\sigma = [0{,}229, 0{,}224, 0{,}225]$.

Con Data Augmentation (Dominio Portuario)

Diseñado para cubrir la variabilidad específica del dominio:

- **RandomCrop** desde 256×256: simula diferentes encuadres de cámara.
- **RandomHorizontalFlip** (p=0,5) y **RandomVerticalFlip** (p=0,1): variabilidad de orientación.
- **RandomRotation** ($\pm$15ř): diferentes ángulos de instalación de cámaras.
- **ColorJitter** (brillo, contraste, saturación): variabilidad de iluminación día/noche.
- **RandomPerspective** (p=0,3): diferentes puntos de vista y distorsiones de lente.
- **RandomGrayscale** (p=0,05): simula cámaras en blanco y negro.

Arquitecturas de Red

Modelo desde cero — SimpleCNN

Red convolucional ad-hoc con cuatro bloques convolucionales progresivos ($32 \to 64 \to 128 \to 256$ filtros), cada uno con BatchNorm y MaxPooling, seguidos de capas densas con Dropout (0.5). Parámetros entrenables: **2,487,553**.

Modelo preentrenado — ResNet18 Fine-tuning

ResNet18 con pesos preentrenados en ImageNet. Se sustituye la capa *fully-connected* final por una capa lineal de salida escalar. Se aplica **learning rate diferenciado**: lr=10^{-3} para la cabeza de clasificación y lr=10^{-4} para el backbone. Parámetros entrenables: **11,177,025**.

Configuración de Entrenamiento

Cuadro 3: Hiperparámetros de entrenamiento

Parámetro	**Valor**
Función de pérdida	BCEWithLogitsLoss
Optimizador	Adam
Learning rate	10^{-3} (scratch), diferenciado (pretrain)
Batch size	32
Épocas máximas	50
Scheduler	ReduceLROnPlateau (paciencia 5, factor 0.5)
Early stopping	Paciencia 10 épocas sobre val_loss

Tarea 2 — Clasificación Ship/No-Ship

Curvas de Entrenamiento

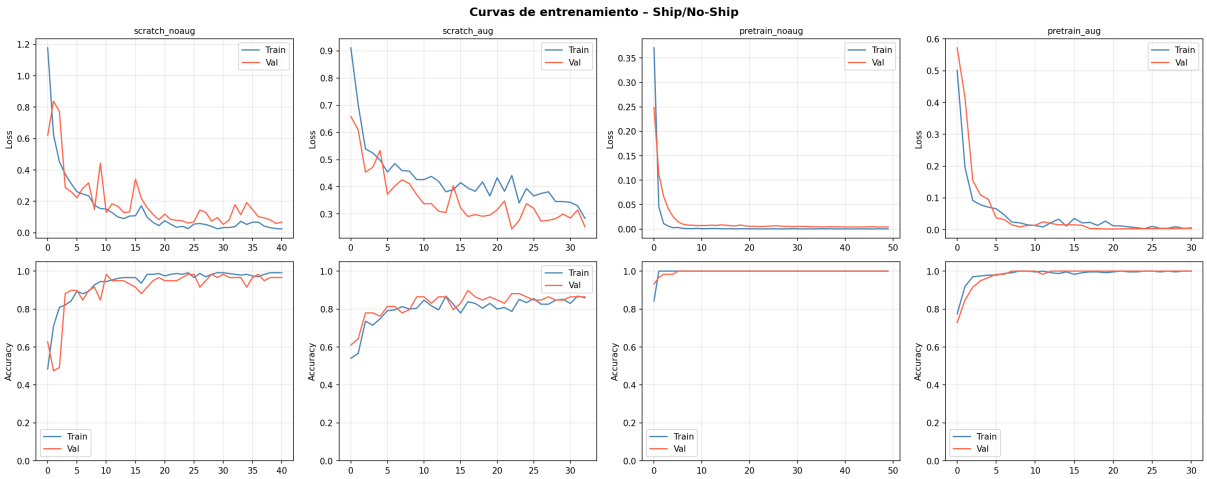

Figura 1: Curvas de pérdida (fila superior) y accuracy (fila inferior) para las cuatro configuraciones en la tarea Ship/No-Ship.

- **scratch_noaug**: converge rápidamente (early stop ép. 41); ligero sobreajuste controlado.
- **scratch_aug**: curvas más ruidosas; el augmentation actúa como regularizador implícito (early stop ép. 33).
- **pretrain_noaug**: convergencia rápida y estable hasta la época 50; pérdidas prácticamente nulas.
- **pretrain_aug**: convergencia similar; early stop en ép. 31 al estabilizarse val_loss.

Resultados Cuantitativos

Cuadro 4: Métricas en validación — Ship/No-Ship (59 imágenes)

Modelo	Accuracy	Precisión	Recall	F1-Score
scratch_noaug	0.983	0.984	0.983	0.983
scratch_aug	0.881	0.888	0.881	0.878
pretrain_noaug	**1.000**	**1.000**	**1.000**	**1.000**
pretrain_aug	**1.000**	**1.000**	**1.000**	**1.000**

Matrices de Confusión

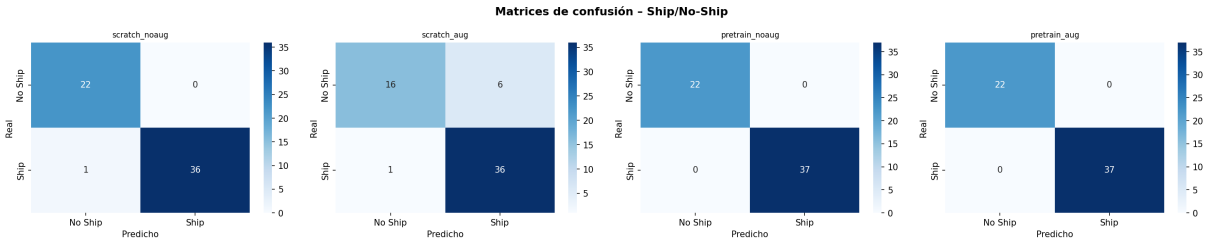

Figura 2: Matrices de confusión — Ship/No-Ship (validación, 59 imágenes).

Análisis

Los modelos preentrenados clasifican correctamente las **59 imágenes** sin ningún error, demostrando la potencia del transfer learning con datasets pequeños. El **scratch_noaug** comete únicamente 1 error (1 Ship clasificado como No-Ship) con F1 = 0.983, resultado excepcional para un modelo desde cero. El **scratch_aug** presenta 7 errores, lo que sugiere que el augmentation agresivo dificulta el aprendizaje con tan pocas imágenes partiendo de pesos aleatorios.

Tarea 4 — Clasificación Docked/Undocked (Opcional)

Curvas de Entrenamiento

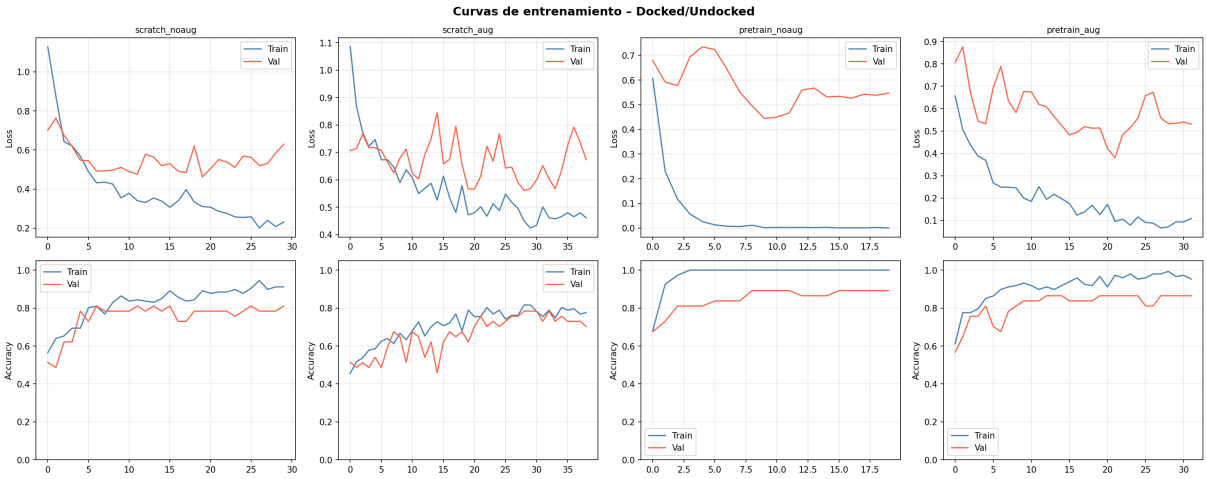

Figura 3: Curvas de pérdida (fila superior) y accuracy (fila inferior) para las cuatro configuraciones en la tarea Docked/Undocked.

La tarea Docked/Undocked presenta una dificultad notablemente mayor. Las curvas de validación muestran alta varianza y una brecha train/val más pronunciada en todos los modelos, indicando mayor dificultad de generalización. Distinguir un barco atracado de uno en movimiento requiere reconocer características más sutiles: presencia de muelles, cabos y posición relativa respecto a la infraestructura portuaria.

Resultados Cuantitativos

Cuadro 5: Métricas en validación — Docked/Undocked (37 imágenes)

Modelo	**Accuracy**	**Precisión**	**Recall**	**F1-Score**
scratch_noaug	0.784	0.816	0.784	0.777
scratch_aug	0.784	0.816	0.784	0.777
pretrain_noaug	**0.892**	**0.911**	**0.892**	**0.890**
pretrain_aug	0.865	0.874	0.865	0.864

Matrices de Confusión

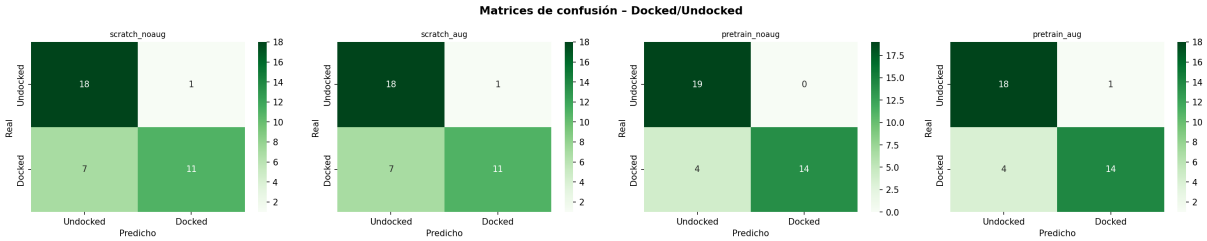

Figura 4: Matrices de confusión — Docked/Undocked (validación, 37 imágenes).

Análisis

El **pretrain_noaug** es el mejor modelo con 89.2 % de accuracy, cometiendo únicamente 4 errores (todos en la clase Docked). Añadir augmentation al modelo preentrenado reduce ligeramente el rendimiento (86.5 %), posiblemente porque las transformaciones geométricas distorsionan las características espaciales críticas para identificar el estado de atraque. Los modelos desde cero empatan en 78.4 %, con mayor tasa de error en la clase Docked (7 de 18 incorrectos), que resulta la más difícil de reconocer.

Comparativa Global y Conclusiones

Comparativa entre tareas

Cuadro 6: Comparativa global de todos los modelos

Tarea	Modelo	Acc	Prec	Rec	F1
Ship/No-Ship	scratch_noaug	0.983	0.984	0.983	0.983
	scratch_aug	0.881	0.888	0.881	0.878
	pretrain_noaug	**1.000**	**1.000**	**1.000**	**1.000**
	pretrain_aug	**1.000**	**1.000**	**1.000**	**1.000**
Docked/Undocked	scratch_noaug	0.784	0.816	0.784	0.777
	scratch_aug	0.784	0.816	0.784	0.777
	pretrain_noaug	**0.892**	**0.911**	**0.892**	**0.890**
	pretrain_aug	0.865	0.874	0.865	0.864

Conclusiones

1. **Transfer learning es clave con datasets pequeños.** ResNet18 preentrenado supera consistentemente a SimpleCNN en ambas tareas, tanto en rendimiento final como en velocidad de convergencia.
2. **Ship/No-Ship queda prácticamente resuelto.** Los modelos preentrenados alcanzan accuracy perfecto (100 %). Incluso SimpleCNN sin augmentation logra F1 = 0.983, lo que indica que la tarea presenta suficiente señal visual para modelos sencillos.
3. **Docked/Undocked es significativamente más difícil.** El mejor modelo (pretrain_noaug, 89.2 %) deja margen de mejora. La alta varianza en validación indica que 184 imágenes son insuficientes para esta tarea más sutil.
4. **El data augmentation no siempre mejora.** En Ship/No-Ship ralentiza la convergencia sin beneficio. En Docked/Undocked reduce ligeramente el rendimiento, posiblemente al distorsionar características espaciales relevantes para el estado de atraque.

5. **Modelo recomendado para producción: pretrain_noaug**, por su mayor accuracy, convergencia estable y comportamiento predecible en ambas tareas.